

Bayesian Model Averaging

Giuditta Adezio, Mattia Ottolenghi

Università degli Studi di Milano-Bicocca

1 Introduzione

Nell'ambito dell'inferenza statistica, la scelta del modello rappresenta una fonte di incertezza spesso sottovalutata. Affidarsi a un unico modello equivale ad assumere implicitamente che esso sia quello corretto, trascurando il fatto che diversi modelli possano descrivere i dati in modo ugualmente ragionevole. Ignorare questa incertezza strutturale può portare a inferenze troppo ottimistiche riguardo alla precisione delle stime ottenute. Una risposta naturale a questo problema consiste nel considerare simultaneamente più modelli e nel combinarli in modo coerente. In ambito bayesiano, questo approccio prende il nome di *Bayesian Model Averaging* (BMA): anziché selezionare un unico modello, le inferenze vengono ottenute come media ponderata sui modelli considerati, dove i pesi sono proporzionali alla probabilità a posteriori di ciascun modello. L'incertezza sulla struttura del modello viene, quindi, propagata nelle stime finali producendo risultati più robusti. Effettuare una media su tutti i modelli possibili è tuttavia spesso computazionalmente proibitivo, specialmente al crescere del numero di variabili. La stima di ciascun modello candidato è stata effettuata tramite *Markov Chain Monte Carlo* (MCMC), mediante il quale si ottiene un campione dalla distribuzione a posteriori dei coefficienti β , necessario per il calcolo dei pesi BMA e delle distribuzioni predittive. Vale la pena sottolineare che la nozione di "modello migliore" dipende dal criterio adottato per la valutazione, ad esempio in termini di accuratezza predittiva o di bontà di adattamento. Il principale vantaggio del BMA rispetto alla selezione classica di un unico modello risiede proprio nella capacità di evitare una scelta rigida, integrando invece le informazioni provenienti da più modelli e riflettendo in modo più onesto l'incertezza presente nei dati. Il lavoro presentato di seguito illustra un'applicazione del BMA sia su dati simulati che su dati reali, con particolare attenzione alla sua utilità nel contesto della classificazione binaria con diverse funzioni link disponibili (logit, probit, cloglog).

2 Applicazione su dati simulati

Per mostrare nella pratica l'utilizzo di tale tecnica, si è ricorso, come primo approccio, a un esempio simulativo. Il dataset è stato costruito simulando 200 osservazioni relative a 6 predittori. I primi quattro predittori sono stati generati indipendentemente da una distribuzione

normale standard: $X_1, X_2, X_3, X_4 \sim \mathcal{N}(0, 1)$. Gli ultimi due predittori sono stati costruiti come combinazioni lineari dei primi due, aggiungendo rumore gaussiano:

$$X_5 = 0.5X_1 + 1.2X_2 + \varepsilon_5,$$

$$X_6 = 0.5X_1 + 1.2X_2 + \varepsilon_6,$$

dove $\varepsilon_5, \varepsilon_6 \sim \mathcal{N}(0, 1)$, indipendenti tra loro e dagli altri predittori. In questo modo, X_5 e X_6 risultano fortemente correlati con X_1 e X_2 , creando difficoltà per i modelli. La variabile lineare è definita come:

$$\eta = X_1 + X_2 + X_3 + \varepsilon,$$

dove $\varepsilon \sim \mathcal{N}(0, 1)$. La probabilità della variabile risposta è ottenuta tramite funzione logistica: $p = 1/(1 + e^{-\eta})$. La variabile risposta binaria è generata come: $Y | X \sim \text{Bernoulli}(p)$. Il test è stato generato con lo stesso procedimento, ma con un quarto della numerosità del training.

I dati simulati sono stati utilizzati per stimare tre tipologie di modelli di regressione per variabili binarie, differenziati esclusivamente dalla funzione di link: logit, probit e complementary log-log (cloglog). La struttura comune dei modelli è: $g(p) = \eta$, dove $g(\cdot)$ rappresenta la funzione di link specifica del modello e η è il predittore lineare costruito a partire dai regressori. Le tre specificazioni considerate sono:

- modello logit: $p = 1/(1 + \exp(-\eta))$
- modello probit: $p = \Phi(\eta)$
- modello cloglog: $p = 1 - \exp(-\exp(\eta))$

Per ciascun modello è stato implementato un file Stan separato, in cui sono specificate la distribuzione della variabile risposta e la corrispondente trasformazione del predittore lineare in probabilità.

La distribuzione a priori sui coefficienti di regressione β è stata specificata come una normale multivariata: $\beta \sim \mathcal{N}_p(\beta_0, \Sigma_0)$, dove β_0 e Σ_0 rappresentano rispettivamente il vettore di medie e la matrice di covarianza a priori. La dimensione p in esame pari a 6 covariate più l'intercetta, per un totale di 2^p modelli possibili da stimare, per ogni funzione link.

L'utilizzo di una prior normale multivariata è motivato da due ragioni principali. In primo luogo, consente di regolarizzare le stime dei coefficienti, riducendo problemi di instabilità numerica, in particolare in presenza di correlazione tra i predittori. In secondo luogo, permette di incorporare eventuali informazioni a priori in modo flessibile e interpretabile. Questa scelta favorisce inoltre una migliore efficienza nella stima MCMC, grazie alla struttura semi-coniugata rispetto al predittore lineare.

La medesima struttura a priori è stata adottata in modo coerente per i modelli probit e cloglog, così da garantire piena confrontabilità tra le diverse funzioni di link.

I tre modelli sono stati successivamente combinati tramite Bayesian Model Averaging (BMA), al fine di incorporare simultaneamente due fonti di incertezza: la scelta della funzione di link

e la selezione delle covariate. Lo spazio dei modelli candidati è dato dal prodotto cartesiano tra le 3 funzioni di link disponibili (logit, probit, cloglog) e i $2^6 = 64$ possibili sottoinsiemi delle 6 covariate, per un totale di $3 \times 64 = 192$ modelli. La distribuzione predittiva marginale risultante è:

$$p(Y | \mathbf{X}, \mathcal{D}) = \sum_{j=1}^3 \sum_{l=1}^{64} w_{jl} p(Y | \mathbf{X}, M_{jl}, \mathcal{D}), \quad (1)$$

dove M_{jl} denota il modello con funzione di link j e sottoinsieme di covariate l , $p(Y | \mathbf{X}, M_{jl}, \mathcal{D})$ è la distribuzione predittiva a posteriori sotto M_{jl} , e $w_{jl} = P(M_{jl} | \mathcal{D})$ sono i pesi a posteriori, con $\sum_{j=1}^3 \sum_{l=1}^{64} w_{jl} = 1$.

Dopo aver verificato la convergenza dei traceplots per i modelli, si osservano i seguenti risultati: il coverage è stato eseguito un confronto con il modello nullo, il modello completo e il modello "corretto" (in cui si considerano solo le prime tre variabili, usate per generare la risposta) con tutti e tre i link. Il risultato è riportato in Tabella 2

Model	Coverage	Width
BMA Multi-Link	0.98	0.5888322
Best Overall (logit)	0.80	0.2385450
Nullo (logit)	1.00	0.1111738
Nullo (probit)	1.00	0.1086785
Nullo (cloglog)	0.52	0.1112408
Corretto (logit)	0.76	0.1952303
Corretto (probit)	0.76	0.1937462
Corretto (cloglog)	0.56	0.1816810
Full (logit)	0.80	0.2544469
Full (probit)	0.82	0.2573027
Full (cloglog)	0.66	0.2346514

Tabella 1: Confronto tra modelli in termini di Coverage e Width

Il modello BMA raggiunge un coverage nettamente superiore rispetto agli altri modelli considerati; la maggiore ampiezza degli intervalli predittivi riflette una quantificazione dell'incertezza più completa, che incorpora sia l'incertezza interna a ciascun modello che quella legata alla scelta del modello stesso. Tra i singoli modelli, la funzione di link cloglog tende a produrre coverage inferiori rispetto a logit e probit, che mostrano invece comportamenti molto simili tra loro. Il modello con peso maggiore nella mistura BMA è un modello logit, risultato coerente con il meccanismo generativo dei dati.

Dal punto di vista teorico, il coverage elevato e la maggiore ampiezza degli intervalli di credibilità BMA rispetto ai modelli singoli si spiegano attraverso la decomposizione della varianza della mistura. La varianza a posteriori BMA si scompone come:

$$\text{Var}_{\text{BMA}}(\beta) = \underbrace{\mathbb{E}_M[\text{Var}(\beta | M, \mathbf{y})]}_{\text{varianza intra-modello}} + \underbrace{\text{Var}_M(\mathbb{E}[\beta | M, \mathbf{y}])}_{\text{varianza tra-modelli}} \quad (2)$$

Il primo termine cattura l'incertezza interna a ciascun modello, mentre il secondo, sempre ≥ 0 , cattura la dispersione tra le stime medie dei diversi modelli. La varianza BMA è quindi almeno pari alla media ponderata delle varianze dei singoli modelli, tipicamente maggiore [1]. È noto [2] che un singolo modello condiziona l'inferenza a una struttura fissa, ignorando l'incertezza sulla scelta del modello stesso e producendo intervalli sistematicamente troppo stretti. Gli intervalli BMA tendono ad essere più ampi quando i pesi a posteriori sono distribuiti su più modelli e le stime differiscono sostanzialmente tra loro, come nel nostro caso con tre funzioni di link eterogenee. Al contrario, possono risultare comparabili a quelli dei modelli singoli quando un modello domina nettamente ($w_k \approx 1$) o le stime dei modelli sono molto simili tra loro. In questo senso, gli intervalli più ampi non sono un difetto ma una proprietà desiderabile: la BMA produce stime di incertezza più oneste e calibrate, incorporando sia l'incertezza di ciascun modello che quella tra diversi modelli. Il coverage elevato osservato (0.98) riflette proprio questa caratteristica: la distribuzione predittiva BMA copre un insieme più ampio di valori plausibili, a costo di intervalli più larghi (Width = 0.588).




Figura 1: Distribuzioni MCMC dei coefficienti β_j e relative densità BMA

Il grafico 1 mostra la distribuzione a posteriori dei sette coefficienti β_j (con $j = 1, \dots, 7$): per ciascun parametro sono state tracciate in grigio le densità empiriche dei campioni MCMC dei modelli che includono la variabile associata, sovrapposte alla densità BMA complessiva, così da permettere un confronto diretto tra i contributi dei singoli modelli e la stima aggregata. La densità BMA risulta essere quindi una mistura con pesi a posteriori w_k , come riportato

in equazione (1). Essa riflette direttamente l'incertezza sulla struttura del modello: anziché condizionarsi a un unico modello scelto, si media su tutti i modelli plausibili, ponderando ciascun contributo in proporzione alla sua verosimiglianza a posteriori. Il risultato, mostrato in blu, rappresenta la stima aggregata dell'incertezza sul parametro.

Viene riportata anche la probabilità che il coefficiente sia nullo, ovvero la probabilità di non inclusione nel modello, tramite il complementare della Posterior Inclusion Probability (PIP) ossia: $(1 - \text{PIP}_j = 1 - P(\beta_j \neq 0 \mid \mathbf{y}) = 1 - \sum_{k:j \in \mathcal{M}_k} w_k)$, raffigurata come uno spike verticale in zero (in rosso).

3 Applicazione su dati reali: Pima

Al fine di valutare le prestazioni del modello in un contesto reale, è stato considerato il dataset Pima, relativo a uno studio sulla diagnosi del diabete. A differenza dei dati simulati, in cui il meccanismo generativo è noto, i dati reali introducono incertezza strutturale e pattern complessi, rendendo la valutazione più informativa sulla capacità di generalizzazione del modello. Si sono considerate stessa prior e link utilizzati per l'esempio precedente.

I risultati sono riportati in Tabella 2. In termini di accuratezza, il modello BMA raggiunge lo stesso livello del Best Overall, mostrando che la capacità predittiva è sostanzialmente equivalente tra questi approcci. Il modello cloglog full presenta invece un'accuratezza più bassa degli altri modelli, suggerendo una scarsa adattabilità di questo link ai dati. I modelli nulli, infatti, hanno accuracy di poco inferiore.

Model	Coverage	Width	WAIC	LPML	Accuracy
BMA Multi-Link	0.994	0.776	195.821	-95.675	0.801
Best Overall (logit)	0.886	0.206	191.285	-95.663	0.801
Null (logit)	0.672	0.104	258.267	-129.132	0.672
Null (probit)	0.672	0.106	258.289	-129.144	0.672
Null (cloglog)	0.328	0.086	258.395	-129.197	0.672
Full (logit)	0.898	0.235	195.465	-97.783	0.801
Full (probit)	0.895	0.235	194.183	-97.174	0.801
Full (cloglog)	0.331	0.165	194.360	-97.383	0.759

Tabella 2: Confronto tra modelli sui dati Pima

Sul fronte della calibrazione delle probabilità predittive, il BMA, analogamente al caso simulato, presenta un coverage molto elevato, ma a costo di intervalli di credibilità più ampi. Il modello Best Overall (logit) offre invece un miglior compromesso tra i due aspetti, garantendo un coverage accettabile con intervalli sensibilmente più stretti. In termini di WAIC, il BMA mostra prestazioni leggermente inferiori rispetto ad alcuni modelli singoli, riflettendo il costo dell'averaging tra link eterogenei, soprattutto quando alcuni (come il cloglog) risultano poco adatti ai dati. In termini di LPML, il BMA mostra valori sostanzialmente equivalenti al modello Best Overall, poiché l'averaging consente di mantenere una buona capacità predittiva complessiva.

siva, compensando le eventuali scarse prestazioni di alcuni modelli con il contributo di quelli meglio adattati.

Confronto con Bagging

A titolo di confronto con un metodo ensemble frequentista, è stato considerato il **Bagging** (Bootstrap Aggregating) tramite alberi decisionali.

Dal grafico in Figura 2, la variabile `glu` risulta di gran lunga la più rilevante, seguita da `age`, `ped` e `bmi`. Le variabili `bp` e `skin` risultano invece le meno informative, coerentemente con quanto emerso anche all'analisi BMA tramite le PIP.




Figura 2: Variable Importance per bagging vs Posterior Inclusion Probability per BMA

Il confronto tra i due approcci, in termini di capacità di distinguere tra classi, è riportato nella curva ROC in Figura 3. La BMA ottiene un'AUC pari a 0.865, superiore a quella del Bagging (0.807), suggerendo una migliore capacità discriminativa complessiva. Questo risultato è notevole, la maggiore AUC della BMA può essere attribuita alla sua capacità di incorporare l'incertezza di tutti i modelli, producendo probabilità predittive meglio calibrate.




Figura 3: ROC per Bagging e BMA

Bibliografia

- [1] Jennifer A. Hoeting, David Madigan, Adrian E. Raftery, and Chris T. Volinsky. Bayesian model averaging: A tutorial. *Statistical Science*, 14(4):382–417, 1999.
- [2] David Madigan and Adrian E. Raftery. Model selection and accounting for model uncertainty in graphical models using Occam’s window. *Journal of the American Statistical Association*, 89(428):1535–1546, 1994.
- [3] National Institute of Diabetes, Digestive, and Kidney Diseases. Pima indians diabetes dataset. Disponibile nel pacchetto MASS in R.
- [4] Adrian E Raftery, David Madigan, and Jennifer A Hoeting. Bayesian model averaging for linear regression models. *Journal of the American Statistical Association*, 92(437):179–191, 1997.